

Benchmark SOTA - Documentación

Descripción

Este documento describe el nuevo **Benchmark SOTA (State-of-the-Art)** implementado para evaluar el sistema RAG+GPT con criterios estrictos.

Diferencias entre Benchmarks

Benchmark Antiguo (Permisivo)

- **Criterio:** Pares únicos (note_id, concept_id)
- **Total Anotaciones:** 64 pares únicos
- **Matching:** Solo requiere que exista el concepto en la nota (ignora localización)
- **Métrica:** F1-Score simple (micro-average)

Benchmark SOTA (Estricto)

- **Criterio:** Match exacto con 3 condiciones:
 1. Mismo **note_id**
 2. Mismo **concept_id**
 3. **IoU (Intersection over Union) > 0.5** en los spans
- **Total Anotaciones:** 115 anotaciones completas del ground truth
- **Matching:** Requiere localización precisa ($\pm 50\%$ de solapamiento)
- **Métrica:** **Macro-Average F1-Score** (promedio de F1 por nota)

Fórmula del IoU

El **Intersection over Union (IoU)** mide el solapamiento entre dos spans:

\$\$

$$\text{IoU}(P, G) = \frac{|\text{span}_P \cap \text{span}_G|}{|\text{span}_P \cup \text{span}_G|}$$

\$\$


Donde:

- span_P = span predicho (caracteres desde **start** hasta **end**)
- span_G = span del ground truth
- $\cap$ = intersección (caracteres en común)
- $\cup$ = unión (caracteres totales cubiertos por ambos)

Umbral: $\text{IoU} \geq 0.5$ para considerar un match válido

Ejemplos de IoU:

1. **Match perfecto** ($\text{IoU} = 1.0$):



```
Ground Truth: "CT angiography" [520-534]
Predicción:   "CT angiography" [520-534]
IoU = 14/14 = 1.0 ✓
```

2. Match parcial válido (IoU = 0.67):

```
Ground Truth: "CT angiography" [520-534]
Predicción:   "angiography"    [523-534]
IoU = 11/14 ≈ 0.79 ✓
```

3. Match insuficiente (IoU = 0.33):

```
Ground Truth: "CT angiography" [520-534]
Predicción:   "CT"             [520-522]
IoU = 2/14 ≈ 0.14 ✗
```

Cálculo del Macro-Average F1

El **Macro-Average F1** se calcula en dos pasos:

Paso 1: Calcular F1 por Nota

Para cada nota i (del 1 al 5):

1. Contar anotaciones:

- GT_i = anotaciones del ground truth en la nota i
- $Pred_i$ = predicciones en la nota i

2. Hacer matching 1-a-1 (con $IoU \geq 0.5$):

- TP_i = True Positives (predicciones que matchean con GT)
- $FP_i = |Pred_i| - TP_i$ (predicciones sin match)
- $FN_i = |GT_i| - TP_i$ (anotaciones GT no detectadas)

3. Calcular métricas:

\$\$

$$\text{Precision}_i = \frac{TP_i}{TP_i + FP_i}$$

\$\$

\$\$

$$\text{Recall}_i = \frac{TP_i}{TP_i + FN_i}$$

\$\$

\$\$

$$F1_i = 2 \cdot \frac{\text{Precision}_i \cdot \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i}$$

\$\$

Paso 2: Promediar F1 Scores

\$\$

$$F1_{\text{Macro}} = \frac{1}{N} \sum_{i=1}^N F1_i$$

\$\$

Donde $N = 5$ (número de notas).

Ventaja del Macro-Average: Da igual peso a cada nota, sin importar cuántas anotaciones tenga.

Uso

Ejecutar solo el Benchmark SOTA:

```
cd benchmark/strategies/rag_gpt
python scripts/benchmark_sota.py
```

Ejecutar ambos benchmarks (antiguo + SOTA):

```
cd benchmark/strategies/rag_gpt
python scripts/run_rag_gpt.py
```

Esto ejecutará:

1. El pipeline RAG+GPT sobre las 5 notas
2. El benchmark antiguo (permisivo - 64 pares)
3. El benchmark SOTA (estricto - 115 anotaciones + IoU)

Argumentos opcionales:

```
# Cambiar el umbral de IoU (default: 0.5)
python scripts/benchmark_sota.py --iou-threshold 0.7

# Especificar archivos de entrada
python scripts/benchmark_sota.py \
  --input ../../data/mimic-iv_notes_training_set.csv \
  --truth ../../data/train_annotations.csv

# Silenciar output detallado
python scripts/benchmark_sota.py --no-verbose
```

Resultados Actuales

Benchmark Antiguo (Permisivo):

- F1-Score: **0.7857**
- Precision: 0.9167
- Recall: 0.6875
- Pares matched: 44/64

Benchmark SOTA (Estricto):

- **F1-Score Macro-Average: 0.2625**
- Precision (Micro): 0.3710
- Recall (Micro): 0.2000
- Anotaciones matched: 23/115 (20%)

Resultados por Nota (SOTA):

Nota	GT Annotations	Predictions	TP	FP	FN	Precision	Recall	F1-Score
1	33	15	8	7	25	0.5333	0.2424	0.3333
2	16	12	6	6	10	0.5000	0.3750	0.4286
3	23	9	3	6	20	0.3333	0.1304	0.1875
4	22	9	4	5	18	0.4444	0.1818	0.2581
5	21	17	2	15	19	0.1176	0.0952	0.1053

Macro-Average F1: $(0.3333 + 0.4286 + 0.1875 + 0.2581 + 0.1053) / 5 = \mathbf{0.2625}$

Análisis de Resultados

Problemas Identificados:

1. Gran brecha entre benchmarks (0.79 vs 0.26):

- El benchmark antiguo no penaliza errores de localización
- El sistema encuentra conceptos correctos pero en posiciones incorrectas

2. Baja Recall (20%):

- 92/115 anotaciones del ground truth no son detectadas
- Problema principal: **NER no extrae suficientes entidades**
- O bien: **RAG/Coding mapea a conceptos incorrectos**

3. Precision moderada (37%):

- 39/62 predicciones no tienen match en el ground truth
- Posibles causas:
 - Spans mal localizados ($IoU < 0.5$)

- Conceptos SNOMED incorrectos
- Entidades espurias extraídas por NER

4. Notas 3 y 5 críticas (F1 < 0.20):

- Requieren análisis detallado para identificar patrones de fallo

Próximos Pasos:

1. **Análisis de spans fallidos:** Ver qué IoU tienen las predicciones que fallan
2. **Diagnóstico NER:** Identificar qué entidades del GT no son extraídas
3. **Diagnóstico RAG/Coding:** Ver qué entidades NER son mal codificadas
4. **Mejora de localización:** Ajustar lógica de `find_span_in_text` para mejor precisión

Archivos

- `scripts/benchmark_sota.py`: Script principal del benchmark SOTA
- `scripts/run_rag_gpt.py`: Script que ejecuta ambos benchmarks
- `scripts/analyze_missing_pairs.py`: Análisis de pares faltantes (benchmark antiguo)

Referencias

- Train annotations: `benchmark/data/train_annotations.csv` (115 anotaciones)
- Input notes: `benchmark/data/mimic-iv_notes_training_set.csv` (5 notas)
- Metrics calculator: `benchmark/evaluation/metrics_calculator.py` (benchmark antiguo)